

UNIVERSIDAD CATOLICA BOLIVIANA “SAN PABLO”



SISTEMA DE VIDEOVIGILANCIA CON INTELIGENCIA ARTIFICIAL PARA DETECCIÓN DE INTRUSOS

INTELLIGENT VIDEO SURVEILLANCE SYSTEM FOR INTRUDER DETECTION

DOCENTE: ING. EDGAR JALDIN TORRICO

MATERIA: INTELIGENCIA ARTIFICIAL

AUTOR:

JOSE AGUSTIN MENDOZA UREÑA

Estudiante de ingeniería de software

en la universidad católica boliviana sede San Pablo

SANTA CRUZ – BOLIVIA

Resumen

El objetivo de la investigación fue desarrollar un sistema de visión artificial basado en la estimación de posturas para la detección precisa de intrusiones perimetrales, evaluando su capacidad de generalización en escenarios reales. Para ello, se aplicó un enfoque cuantitativo y experimental utilizando Transfer Learning mediante la plataforma Teachable Machine sobre la red preentrenada PoseNet; se construyó un conjunto de datos de 1600 imágenes, incorporando intencionalmente casos adversarios en la clase normal para evitar el sobreajuste por sesgo de contexto, y se implementó un filtro de persistencia temporal de 10 fotogramas durante la fase de inferencia. Los resultados evidenciaron que el modelo clasifica la anomalía de forma estable superando el umbral de confianza del 80%, mientras que la lógica de retardo temporal eliminó exitosamente los falsos positivos producidos por oclusiones parciales o movimientos de transición evaluados en fotogramas aislados. En conclusión, la integración de modelos de IA basados en geometría articular, combinados con un curado riguroso de datos y algoritmos de validación temporal, conforman una solución robusta y computacionalmente eficiente para el análisis de comportamiento en tiempo real.

Palabras clave: inteligencia artificial, visión artificial, estimación de postura, aprendizaje automático, casos adversarios.

Abstract

The objective of the research was to develop an artificial vision system based on pose estimation for accurate perimeter intrusion detection, evaluating its generalization capability in real-world scenarios. To this end, a quantitative and experimental approach was applied using Transfer Learning through the Teachable Machine platform over the pre-trained PoseNet network; a dataset of 1600 images was built, intentionally incorporating adversarial cases into the normal class to prevent overfitting due to context bias, and a 10-frame temporal persistence filter was implemented during the inference phase. The results showed that the model classifies the anomaly stably, exceeding the 80% confidence threshold, while the temporal delay logic successfully eliminated false positives caused by partial occlusions or transitional movements evaluated in isolated frames. In conclusion, the integration of AI models based on joint geometry, combined with rigorous data curation and temporal validation algorithms, constitutes a robust and computationally efficient solution for real-time behavior analysis.

Keywords: artificial intelligence, computer vision, pose estimation, machine learning, adversarial cases.

Introducción

La seguridad física de infraestructuras ha dependido históricamente de sistemas de circuito cerrado de televisión (CCTV) para el monitoreo perimetral. Sin embargo, las cámaras de seguridad tradicionales presentan una limitación arquitectónica fundamental: son dispositivos estrictamente pasivos. Su función operativa se limita a la captura y almacenamiento de video continuo, careciendo de la capacidad computacional nativa para analizar el contenido visual, detectar infiltraciones en progreso o emitir alertas de manera autónoma. Esta dependencia absoluta de la supervisión humana en tiempo real genera cuellos de botella operativos, fatiga visual en los operadores y prolongados periodos de vulnerabilidad.

Para mitigar esta deficiencia, los sistemas de seguridad convencionales han integrado detectores de movimiento basados en algoritmos de sustracción de fondo o alteración de píxeles. No obstante, en entornos exteriores, estas soluciones resultan deficientes al ser altamente susceptibles al ruido ambiental. Cambios bruscos de iluminación, movimiento de vegetación por el viento o el tránsito de animales detonan una tasa inaceptable de falsos positivos, lo que comúnmente lleva a la desactivación de las alertas por parte de los usuarios. Frente a este desafío técnico, la visión artificial y el aprendizaje automático ofrecen un cambio de paradigma, dotando a los sistemas de la capacidad de comprender semánticamente la geometría y el comportamiento de los sujetos, superando el simple análisis de alteraciones en los píxeles.

Dentro de este campo, las redes neuronales convolucionales especializadas en la estimación de posturas humanas, como PoseNet, logran identificar a una persona en el encuadre y trazar un mapa vectorial de sus articulaciones principales. Al trasladar el análisis de la imagen cruda hacia la evaluación de estos vectores espaciales (el esqueleto), el sistema adquiere la capacidad de clasificar posturas específicas. Esto permite establecer fronteras de decisión matemáticas precisas entre un comportamiento inofensivo, como una persona caminando cerca de un muro, y una amenaza real, como un individuo elevando su centro de gravedad y extendiendo los brazos para trepar dicho obstáculo.

El presente manuscrito expone los resultados de una monografía desarrollada para el nivel de Licenciatura en Ingeniería de Software. El objetivo de la investigación fue desarrollar y evaluar un sistema de visión artificial basado en la estimación de posturas para la detección precisa de intrusiones perimetrales. A través del entrenamiento de un modelo binario enfocado en aislar la anomalía geométrica del escalamiento, y la implementación de un algoritmo de persistencia temporal para descartar oclusiones

transitorias, se busca demostrar que la integración de redes neuronales de inferencia rápida constituye una solución robusta y autónoma para transformar hardware de vigilancia pasivo en sistemas de alerta temprana activa.

Metodología

La investigación se desarrolló bajo un enfoque cuantitativo y un diseño preexperimental. La recolección de datos se basó en la construcción de un conjunto de datos (dataset) propio conformado por 1600 imágenes, estructurado para entrenar un modelo de clasificación binaria asimétrica.

La muestra se dividió en dos categorías. La primera, denominada clase de Anomalía (Escalamiento), constó de 400 imágenes capturadas a una distancia de 2 a 3 metros para garantizar la extracción completa de los puntos articulares. En la captura de esta muestra se aplicó una técnica estricta de exclusión de fotogramas de transición; se omitieron deliberadamente las posturas previas y posteriores a la acción (aproximación al muro y descenso con apoyo plantar completo) para evitar el envenenamiento de los datos. Esta clase se segmentó en cuatro posturas de 100 imágenes cada una: suspensión estática en perfil izquierdo con soporte de peso, suspensión estática en perfil derecho, impulso final en perfil izquierdo con elevación corporal mediante presión palmar descendente, y su equivalente geométrico en el perfil derecho.

La segunda categoría, denominada clase Normal (Fondo Universal), se conformó por 1200 imágenes capturadas a distancias variables de 1, 3 y 5 metros. Esta clase se diseñó para mapear el espacio geométrico inofensivo y se subdividió en cuatro lotes de 300 imágenes: un lote de movimiento base (desplazamientos laterales, frontales y posturas estáticas de reposo); un lote de variación del centro de gravedad (sujeto sentado, agachado o en cuclillas); un lote de casos adversarios geométricos (sujeto con apoyo plantar firme, pero con elevación máxima de las extremidades superiores simulando estiramientos o saludos); y un lote de oclusión severa, compuesto por imágenes de esqueletos incompletos capturados a corta focal o segmentados por obstáculos físicos como mobiliario.

Para el análisis y modelado de los datos, se aplicó la técnica de Transfer Learning utilizando la red neuronal preentrenada PoseNet, exportando los pesos matemáticos a un entorno web (TensorFlow.js). Finalmente, el procedimiento de validación para la inferencia en tiempo real se llevó a cabo mediante el diseño de un script de evaluación asíncrona acoplado a un filtro de persistencia temporal (debounce temporal), configurado para exigir la validación estática de la anomalía durante un mínimo de 10

fotogramas continuos antes de ejecutar la comunicación HTTP hacia el servidor de alertas.

Resultados

El entrenamiento del modelo de red neuronal convolucional se ejecuta utilizando los hiperparámetros de 50 épocas, un tamaño de lote de 32 y una tasa de aprendizaje de 0.001. La evaluación del clasificador se realiza sobre un conjunto de datos de prueba automático, correspondiente al 15% del total de la muestra (240 imágenes vírgenes no vistas durante el entrenamiento). La evaluación del rendimiento métrico demuestra una separación de clases altamente efectiva.

En la evaluación de precisión por clase, el modelo alcanza un 100% de exactitud tanto para el estado inofensivo como para la anomalía. Estos datos indican que la inclusión intencional de casos adversarios y oclusiones en la clase mayoritaria permite a la red neuronal discriminar correctamente falsos positivos geométricos. La Figura 1 detalla la matriz de confusión resultante del conjunto de prueba.




Figura 1. Matriz de confusión del modelo binario sobre el conjunto de datos de prueba. Nota.

El análisis de la matriz de confusión evidencia una clasificación perfecta, donde 100% (180) de las muestras correspondientes a la clase Normal son predichas correctamente, y 100% (60) de las muestras de la clase Treapando son identificadas sin desviación. La

ausencia de falsos negativos en la detección de la anomalía garantiza la viabilidad del sistema para su despliegue como alerta temprana.

Respecto al proceso de aprendizaje, las curvas de precisión y pérdida (*Loss*) revelan una rápida convergencia geométrica. La Figura 2 ilustra la curva de pérdida durante las 50 épocas de entrenamiento.




Figura 2. Evolución de la pérdida (Loss) en los conjuntos de entrenamiento y prueba por época.

El comportamiento de las curvas indica que el modelo aprende la diferenciación vectorial de los esqueletos de forma acelerada, alcanzando la estabilidad cerca de la época 10. La ausencia de divergencia entre la curva de entrenamiento (azul) y la curva de prueba (naranja) en las épocas posteriores demuestra empíricamente que el modelo generaliza de manera óptima y no sufre de sobreajuste o memorización de los datos de fondo.

Finalmente, los resultados de la inferencia asíncrona en el entorno de producción (Javascript/Flask) revelan que la precisión estática del modelo requiere regulación temporal. Las pruebas en tiempo real indican que la evaluación de fotogramas aislados produce detecciones prematuras durante los movimientos iniciales del sujeto. Estos datos indican que la implementación de un filtro de persistencia lógica en el software cliente, configurado para requerir una validación continua de 10 fotogramas sobre el umbral de 80% de confianza, elimina eficazmente las falsas alarmas provocadas por el ruido temporal y la inestabilidad instantánea del sensor.

Discusion

La discusión de los resultados obtenidos se fundamenta en una comparativa técnica entre la arquitectura de estimación de posturas propuesta y las tecnologías de detección convencionales, analizando variables de fiabilidad, ruido operativo y eficiencia en la clasificación de datos.

Análisis Comparativo frente a Sensores PIR (Hardware)

El uso de sensores de infrarrojo pasivo (PIR) constituye una de las soluciones de hardware más extendidas debido a su optimización de recursos y bajo consumo de ancho de banda. No obstante, su implementación en exteriores enfrenta desafíos críticos relacionados con la vulnerabilidad ambiental. La precisión de los sensores PIR decae ante variaciones térmicas bruscas, luz solar directa o el tránsito de fauna, lo que genera una tasa de falsas alarmas (FAR) elevada en entornos no controlados (Hao et al., 2007).

Frente a esta limitación, el sistema de IA desarrollado mediante PoseNet ofrece una inmunidad intrínseca a los diferenciales de radiación térmica. Mientras que el hardware PIR requiere de arquitecturas complejas basadas en redes de sensores o algoritmos de procesamiento de señal para mejorar su fiabilidad (Popescu et al., 2015), la red neuronal utilizada en este proyecto traslada la discriminación al dominio visual. Esto permite separar el ruido ambiental de la presencia humana mediante la detección de vectores articulares, superando la incapacidad nativa de discriminación de los sensores infrarrojos individuales, a pesar de que estos últimos presentan una ventaja teórica en cuanto a la inmunidad a la varianza de iluminación (Luo et al., 2016).

Evaluación frente al Video Motion Detection (VMD - Software)

Al contrastar la propuesta con el Video Motion Detection (VMD) tradicional, se identifica una diferencia conceptual en el propósito de los datos. El VMD clásico, basado en el análisis de cambio de valores en la matriz de píxeles, es una herramienta eficaz para la gestión de almacenamiento y la reducción de "video muerto" en sistemas de gestión de video, pero resulta deficiente como clasificador de intrusiones en exteriores. Los sistemas basados puramente en VMD suelen generar una tasa de falsos positivos inaceptablemente alta ante cambios de iluminación, lluvia o sombras, provocando la denominada "fatiga de alertas" en los operadores (DAVANTIS, 2021).

La arquitectura implementada en esta investigación representa la evolución hacia el *Edge-AI*. En lugar de reaccionar ante cualquier alteración en los píxeles, el sistema

incorpora una capa de inferencia que filtra el ruido visual a través de la clasificación de posturas. Esta capacidad de análisis semántico es lo que permite al modelo ignorar el movimiento de objetos inanimados que normalmente saturarían un sistema basado en VMD.

Importancia de la Persistencia Temporal

Finalmente, los resultados evidencian que, aunque las redes neuronales proporcionan una clasificación superior al hardware binario, la inferencia fotograma a fotograma puede generar detecciones prematuras. La implementación del filtro de persistencia temporal (*debounce* de 10 fotogramas) actúa como una capa de lógica de negocio que valida la anomalía antes de su notificación. Este enfoque mitiga el riesgo de falsos positivos instantáneos y alinea el proyecto con las prácticas modernas de analítica de video, donde la verificación visual y la clasificación precisa de comportamientos humanos son fundamentales para establecer un sistema de alerta temprana efectivo.

Conclusiones

La investigación confirma que la implementación de modelos de estimación de posturas basados en la red PoseNet permite transformar dispositivos de captura pasiva en sensores de vigilancia activa con un alto grado de especificidad. El entrenamiento del modelo binario asimétrico demostró que la segregación de la acción de escalamiento frente a una clase de "fondo universal" que incluya intencionalmente casos adversarios elimina la ambigüedad geométrica que afecta a los sistemas de seguridad convencionales.

Se concluye que la exactitud del 100% obtenida en el conjunto de prueba es resultado directo de un curado de datos que prioriza la pureza de las posturas estáticas, omitiendo los fotogramas de transición. No obstante, la validación en entorno real evidencia que la precisión estadística de la red neuronal es insuficiente por sí sola para el despliegue operativo; la verdadera robustez del sistema reside en la capa de lógica de software adicional.

Con la integración de un filtro de persistencia temporal (*debounce*) de 10 fotogramas constituye se permite distinguir entre una coincidencia geométrica efímera y una acción de intrusión sostenida, garantizando que el disparo de la alerta ocurra únicamente cuando la amenaza se ha consolidado físicamente. En consecuencia, el sistema desarrollado ofrece una alternativa de bajo costo computacional y alta fiabilidad para la

protección perimetral, superando las limitaciones de fatiga de alertas presentes en las tecnologías basadas exclusivamente en la alteración de píxeles o sensores infrarrojos pasivos.

Referencias

DAVANTIS. (2021). *Applying video analytics for accurate intrusion detection and effective visual verification* [Libro blanco]. <https://www.davantis.com/>

Hao, Q., Brady, D., Guenther, B., Burchett, J., Shankar, M., & Feller, S. (2007). Moving targets detection and localization in passive infrared sensor networks. En *10th International Conference on Information Fusion* (pp. 1-6). IEEE.

Luo, X., Guan, Q., Xing, T., et al. (2016). Abnormal Activity Detection Using Pyroelectric Infrared Sensors. *Sensors*, 16(6), 865. <https://doi.org/10.3390/s16060865>

Popescu, M., Hotte, A., Rantz, L., et al. (2015). VAMPIR- An Automatic Fall Detection System Using a Vertical PIR Sensor Array. En *Proceedings of the IEEE International Conference on Pervasive Computing and Communications*. IEEE.